

lab-report

October 26, 2024

1 Laboratorium 1 — Życie na krawędzi

1.1 Wprowadzenie

W tym laboratorium (jak i pewnie w każdym następnym) będę korzystać z PyTorch do operacji na tensorach i sieciach neuronowych.

1.2 Import odpowiednich paczek i definicja użytecznych funkcji

```
[1]: from typing import Any
import IPython.display as d
import torch
import torch.nn as nn
import torchvision.transforms as T
import numpy as np
from PIL import Image

pil_to_tensor = T.PILToTensor()
tensor_to_pil = T.ToPILImage()

def to_grayscale(image: torch.Tensor) -> torch.Tensor:
    convolve = nn.Conv2d(
        in_channels=3,
        out_channels=1,
        kernel_size=1,
        bias=False
    )

    # ITU-R 601-2
    grayscale_weights = [0.299, 0.587, 0.114]

    convolve.weight = nn.Parameter(
        torch.tensor(grayscale_weights).view(1, 3, 1, 1),
        requires_grad=False
    )

    return convolve(image)
```

```

def load_image(path: str, grayscale = False) -> torch.Tensor:
    image: torch.Tensor = pil_to_tensor(Image.open(path))[:3, :, :] / 255.0

    if not grayscale:
        return image
    return to_grayscale(image)

def display(*images: np.ndarray | torch.Tensor) -> None:
    if (len(images) == 0):
        return

    images = [image * 255.0 for image in images]

    pil_images: list[Image.Image] | None = None
    if isinstance(images[0], torch.Tensor):
        pil_images = [tensor_to_pil(image.to(torch.uint8)) for image in images]
    else:
        pil_images = [
            Image.fromarray(image.astype(np.uint8)) for image in images
        ]

    d.display(*pil_images)

def average_pooling(image: torch.Tensor, kernel_size: int) -> torch.Tensor:
    return nn.AvgPool2d(kernel_size)(image)

def gaussian_kernel(size: int, sigma: float = 1.0) -> torch.Tensor:
    half_size: int = size // 2
    i, j = (np.mgrid[-half_size:half_size + 1, -half_size:half_size+1]) \
        .astype(np.float32)

    gaussian_kernel = torch.from_numpy(
        np.exp(-(i**2 + j**2) / (2.0 * sigma**2)),
    )
    gaussian_kernel /= gaussian_kernel.sum()

    return gaussian_kernel

def upscale(image: torch.Tensor, target_size: tuple[int, int]) -> torch.Tensor:
    return torch.squeeze(nn.Upsample(target_size)(
        image.view(1, 1, *image.shape)

```

```

        )))

def apply_detected_edges_to_image(
    image: torch.Tensor,
    edges: torch.Tensor
) -> torch.Tensor:
    image = image[:, :, :]
    image[0][edges == 1.0] = 0.0
    image[1][edges == 1.0] = 0.0
    image[2][edges == 1.0] = 1.0

    return image

```

1.2.1 Główna klasa do detekcji krawędzi metodą Canny'ego

Posiada kilka metod, które mają za zadanie zostać wykonane sekwencyjnie i w finalnym rozrachunku przekształcić wejściowy obraz do binarych wykrytych krawędzi:

- guassian_blur,
- sobel,
- nonmax_suppression,
- threshold.

```
[2]: class CannyEdgeDetector(nn.Module):
    def __init__(self, **kwargs: Any) -> None:
        super().__init__()

        self.image: torch.Tensor | None = None
        self.image_size: tuple[int, int] | None = None
        self.gradient_magnitudes: torch.Tensor | None = None
        self.gradient_directions: torch.Tensor | None = None

        self.gaussian_size: int = kwargs.get("guassian_kernel_size", 3)
        self.gaussian_sigma: float = kwargs.get("guassian_sigma", 1.0)
        self.t: float = kwargs.get("threshold", 0.0)

    def set_image(self, image: torch.Tensor) -> None:
        self.image = image
        self.image_size = image.shape

    def forward(self, image: torch.Tensor) -> torch.Tensor:
        self.set_image(image)
        self.guassian_blur(self.gaussian_size, self.gaussian_sigma)
        self.sobel()
        self.nonmax_suppression()
        self.threshold(self.t)
```

```

    return self.image

def guassian_blur(
    self,
    kernel_size: int,
    sigma: float = 1.0
) -> torch.Tensor:
    convolve = nn.Conv2d(
        in_channels=1,
        out_channels=1,
        kernel_size=kernel_size,
        padding=kernel_size // 2,
        bias=False
    )

    kernel = gaussian_kernel(kernel_size, sigma)
    convolve.weight = nn.Parameter(
        kernel.view(1, 1, kernel_size, kernel_size),
        requires_grad=False
    )

    self.image = convolve(self.image)

    return self.image

def sobel(self) -> torch.Tensor:
    sobel_kernel_y = torch.tensor([
        [1, 2, 1],
        [0, 0, 0],
        [-1, -2, -1],
    ], dtype=torch.float)
    sobel_kernel_x = torch.tensor([
        [1, 0, -1],
        [2, 0, -2],
        [1, 0, -1],
    ], dtype=torch.float)

    convolve_gradient = nn.Conv2d(
        in_channels=1,
        out_channels=2,
        kernel_size=3,
        padding=1,
        bias=False
    )
    convolve_gradient.weight = nn.Parameter(
        torch.stack((sobel_kernel_y, sobel_kernel_x)) \
            .view(2, 1, 3, 3),
    )

```

```

        requires_grad=False
    )

convolution_result: torch.Tensor = convolve_gradient(
    self.image
)

self.gradient_magnitudes = convolution_result.pow(2).sum(dim=0).sqrt()
self.gradient_magnitudes \
    = self.gradient_magnitudes / self.gradient_magnitudes.max()
self.gradient_directions = torch.atan2(*convolution_result)

self.image = self.gradient_magnitudes

return self.image

def nonmax_suppression(self) -> torch.Tensor:
    M, N = self.image.shape
    S = torch.zeros((M, N), dtype=torch.float)
    angle = self.gradient_directions * 180.0 / np.pi
    angle[angle < 0.0] += 180

    for i in range(1, M - 1):
        for j in range(1, N - 1):
            q = 1.0
            r = 1.0

            # 0°
            if (
                0.0 <= angle[i, j] < 22.5
                or 157.5 <= angle[i, j] <= 180.0
            ):
                q = self.image[i, j + 1]
                r = self.image[i, j - 1]
            # 45°
            elif (22.5 <= angle[i, j] < 67.5):
                q = self.image[i + 1, j - 1]
                r = self.image[i - 1, j + 1]
            # 90°
            elif (67.5 <= angle[i, j] < 112.5):
                q = self.image[i + 1, j]
                r = self.image[i - 1, j]
            # 135°
            elif (112.5 <= angle[i, j] < 157.5):
                q = self.image[i - 1, j - 1]
                r = self.image[i + 1, j + 1]

```

```

        if self.image[i, j] >= q and self.image[i, j] >= r:
            S[i, j] = self.image[i, j]
        else:
            S[i, j] = 0.0

    self.image = S

    return self.image

def threshold(self, threshold: float) -> torch.Tensor:
    self.image = nn.Threshold(threshold, 0.0)(
        self.image
    )
    self.image[self.image >= threshold] = 1.0
    return self.image

```

1.3 Wczytanie obrazu, znormalizowanie go i transformacja do przestrzeni barw szarości

Do wczytywania obrazów wykorzystałem bibliotekę Pillow, którą używam do załadowania obrazu w formacie RGB. Następnie ten obraz przekształcam do odcienni barw szarości za pomocą konwolucji 1×1 .

```
[3]: base_image = load_image("darth-vader.jpg")
image = load_image("darth-vader.jpg", grayscale=True)
display(image)
```



1.4 Zmniejszenie obrazu (downscaling)

Zdecydowałem się wybrać average pooling z powodu uśrednienia krawędzi, dzięki temu obraz się rozmyje (będzie trzeba zastosować mniejsze rozmycie w następnym kroku). Przy wybraniu maximum pooling w każdym kawałku 4×4 wybierany jest najaśniejszy piksel, przekłada się to na większe wyostrzenie obrazu, na większe jego zniekształcenie w lokalnych punktach (maksimum).

```
[4]: image = average_pooling(image, kernel_size=4)
display(image)
```



1.5 Zainicjalizowanie obiektu do detekcji krawędzi

```
[5]: canny = CannyEdgeDetector()
canny.set_image(image)
```

1.6 Rozmycie gaussowskie (redukcja szumów)

Do rozmycia posłuży gaussowski filtr 3×3 o odchyleniu standardowym $\sigma = 0.4666$.

```
[6]: image = canny.gaussian_blur(kernel_size=3, sigma=0.4666)
display(image)
```



1.7 Gradient intensywności

W tym kroku dochodzi do detekcji krawędzi w dwóch osiach, pionowej i poziomej. Do wyznaczenia wartości w danym pikselu posłuży nam odległość wektora wyznaczonego przez obie osie ($\sqrt{G_y^2 + G_x^2}$). Kierunek spadku jest obliczany za pomocą funkcji atan2.

```
[7]: image = canny.sobel()  
display(image)
```



1.8 Redukcja lokalnych niemaksimów gradientu intensywności (non-maximum suppression)

Na powyższym obrazku widać, że krawędzie są zbyt grube w wielu miejscach. Trzeba je zatem wyszupić i pozostawić tylko te najbardziej dominujące lokalnie. Można to osiągnąć za pomocą non-maximum suppression, które działa na podstawie wyliczonego w poprzednim kroku gradientu oraz jego kierunku.

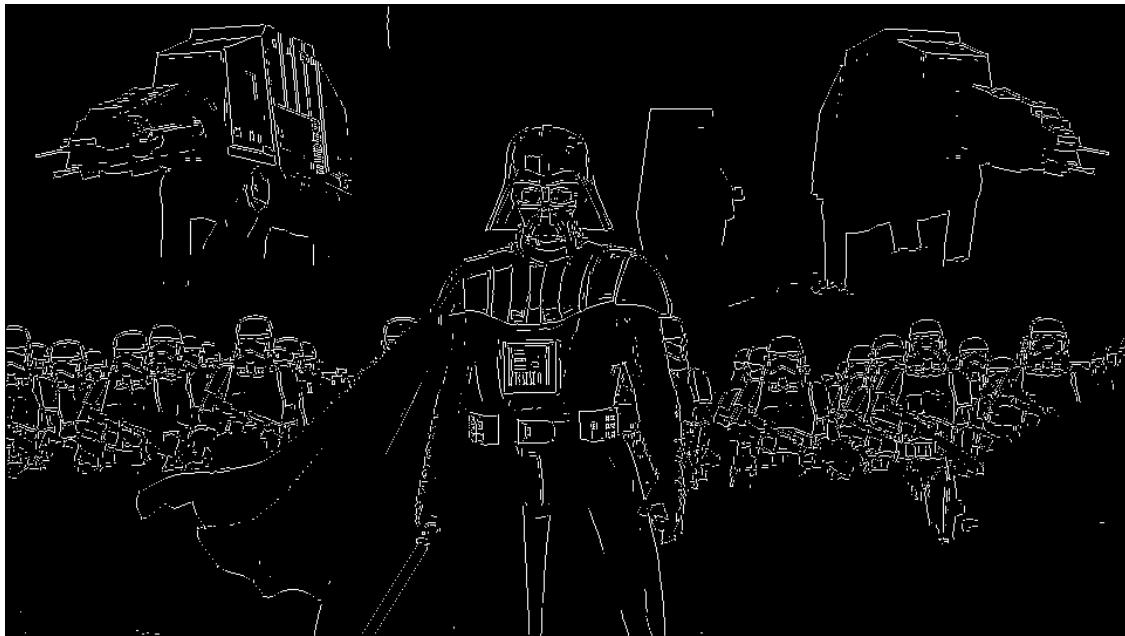
```
[8]: image = canny.nonmax_suppression()  
display(image)
```



1.9 Progowanie

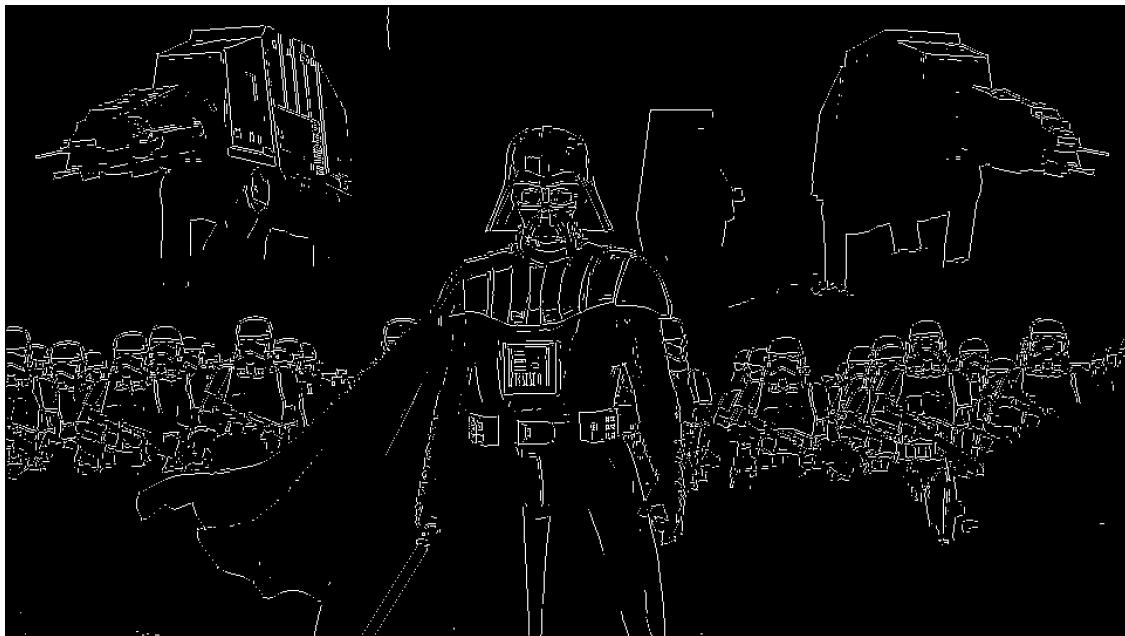
W tym kroku pomineliśmy podwójne progowanie, które dzieli wykryty piksel krawędzi na 3 klasy: mocną, słabą i niezwiązaną; w naszym sposobie są tylko 2: mocna i niezwiązana. Kategoria mocna i niezwiązana świadczy o pewności detekcji, natomiast klasa średkowa - słaba - implikuje brak pewności, który będzie trzeba rozpatrzyć. Dzięki podwójnemu progowaniu jakość detekcji wzrasta za pomocą histerezy, która jest wykonywana po progowaniu.

```
[9]: image = canny.threshold(threshold=0.055)  
display(image)
```



1.10 Powiększenie wykrytych krawędzi do wejściowego rozmiaru obrazu (upsampling)

```
[10]: image = upscale(  
    image, target_size=(base_image.shape[1], base_image.shape[2])  
)  
display(image)
```



1.11 Nałożenie krawędzi na obraz

```
[11]: image = apply_detected_edges_to_image(base_image, image)
display(image)
```



Widać, że krawędzie zostały wykryte dobrze, pozycje pokrywają się z krawędziami na obrazie wejściowym — natomiast nie zostały idealne wykryte. Wynika to między innymi z dość jednolitego tła.